Blockchain-2S2026

Lucas Panonko Assis Belchior

Matrícula: 12311BCC068

ColdCard - ML

Detecção de transações com aprendizado de máquina

22 de outubro de 2026

github.com/LuksbellN/ColdCard-ML

01 / VISÃO GERAL

Visão geral do experimento

Objetivo: reconhecer padrões de transações que enviam BTC ao coletor informado no exercício, comparando modelos de classificação.

493.473	504	594,4773 BTC
transações analisadas	transações positivas	recebidos pelo coletor

Pipeline do trabalho

01	→	02	→	03	→	04	→	05
98 blocos		**Transações**		**Rótulos**		**35 atributos**		**Modelos**
Ler os JSONs		Excluir coinbase		Identificar envios		Descrever padrões		Treinar e avaliar

Como os exemplos recebem um rótulo

POSITIVA (1)

Alguma saída envia BTC ao coletor.

REFERÊNCIA (0)

Nenhuma saída envia ao coletor.

Coletor: **bc1qnk4zh9qcnap2mycp56qjrgza3cc8ylrh8fecp0**

A classe positiva representa só **0,1021%** da base. As demais transações são negativas de referência, sem comprovação de legitimidade. A associação com roubo segue a hipótese do enunciado.

Resultado do modelo escolhido por validação

167 de 168 casos encontrados

Recall: 99,40% | **Precisão: 21,66%** | **604 falsos alarmes**
O modelo recupera quase todos os positivos deste teste, mas seus alertas exigem revisão.

Recorte: 98 blocos não contínuos, alturas 960179 a 960802, entre 30/07 e 03/08/2026 (UTC). Foram excluídas 98 coinbase; não houve duplicatas. Nas positivas, foram gastos 1.329 UTXOs de 504 endereços de entrada distintos. Endereços não equivalem a pessoas.

Valor exato recebido: **594,47725695 BTC**. O recorte fornecido não representa toda a blockchain.

02 / METODOLOGIA

Preparação e treinamento

O modelo observa a estrutura, sem receber o endereço coletor

Quantidade e tamanho	Valores e taxas	Estrutura técnica
Entradas, saídas, bytes e vbytes.	Somas, dispersão, concentração e sat/vB.	Versão, locktime, scripts, witness e RBF.

35 atributos: aplicamos log1p a 16 medidas de tamanho, contagem e valor. Na logística, padronizamos os atributos com médias e desvios calculados só no treino. Hashes, horários, alturas, endereços e o estado futuro das saídas ficam fora do modelo.

Separação por blocos inteiros

DESENVOLVIMENTO	TESTE RESERVADO
370.218 transações | 336 positivas 74 blocos para treinar e escolher configurações	123.255 transações 168 positivas 24 blocos

Nenhum bloco é compartilhado entre desenvolvimento e teste. A distribuição equilibra positivos e tamanho das partições; sementes 42 e 43 tornam a separação reproduzível.

Validação cruzada: treinar em duas partes, validar na terceira

	Parte A: 159 positivas	Parte B: 110 positivas	Parte C: 67 positivas
Rodada 1	**VALIDAR**	**TREINAR**	**TREINAR**
Rodada 2	**TREINAR**	**VALIDAR**	**TREINAR**
Rodada 3	**TREINAR**	**TREINAR**	**VALIDAR**

Cada parte aparece uma vez como validação. Comparamos a média de **Average Precision (AP)** nas três rodadas e escolhemos a configuração antes de olhar o resultado do teste.

Modelos comparados	Como funcionam / configurações
Dummy (referência)	Usa apenas a frequência das classes.
Regressão logística	Combina atributos em um escore. C = 0,1 ou 1,0; pesos de classe balanceados.
Random Forest	Combina escores de 100 árvores de decisão. Profundidade 8 ou 16; mínimo de 5 amostras por folha; pesos balanceados.

Os modelos usam a base completa, sem amostragem ou dados sintéticos. Limiar fixo: escore ≥ 0,5 gera um alerta. O teste não foi usado para ajustar esse limiar.

03 / RESULTADOS

Resultados dos modelos

Modelo	AP valid.	Precisão	Recall	F1	AP teste	ROC-AUC
Dummy	0,0009	0,00%	0,00%	0,0000	0,0014	0,5000
Logística C=0,1 *	0,4723	21,66%	99,40%	0,3557	0,2597	0,9983
Logística C=1,0	0,4635	24,06%	99,40%	0,3875	0,4188	0,9991
RF profundidade 8	0,4273	81,07%	99,40%	0,8930	0,6705	0,9997
RF profundidade 16	0,3792	14,29%	2,98%	0,0493	0,6311	0,9997

*** Selecionado:** logística C=0,1, pela maior AP média de validação (0,4723 ± 0,3985 de desvio padrão). RF com profundidade 8 foi melhor neste teste, mas a escolha anterior foi mantida. A variação entre blocos é grande.

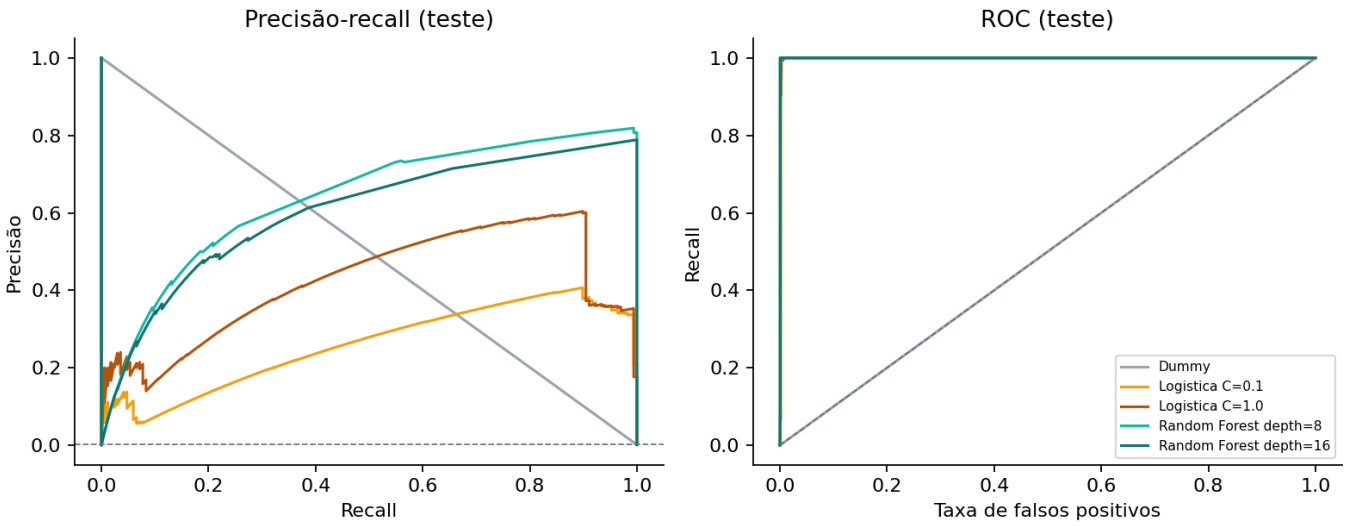
Matriz de confusão do modelo selecionado

	Predito: ref.	Predito: caso
Referência	**122.483**	**604**
ColdCard	**1**	**167**

167 acertos positivos
604 falsos alarmes
1 caso não detectado

771 alertas, dos quais 21,66% são positivos.

Precisão: quantos alertas são positivos. **Recall:** quantos positivos foram encontrados. **F1:** equilíbrio entre os dois. **AP:** resume precisão e recall ao variar o limiar (não é a área trapezoidal).



Curvas no teste reservado. A linha horizontal na PR marca a prevalência (0,1363%). Mesmo sem detectar positivos, o Dummy atinge 99,8637% de acurácia: acurácia alta e ROC-AUC alta, isoladamente, escondem falsos alarmes.

04 / DISCUSSÃO

Análise dos resultados

Um caso real que o modelo não detectou

Transação	Escore calculado	Decisão com limiar 0,5
200 entradas / 1 saída →	**0,4549**	→ **Não gera alerta**

O rótulo real é positivo: 0,31149028 BTC ao coletor. A estrutura difere da mediana das positivas (1 entrada / 1 saída).

Hash: 43520bd70cc83ebc27a6071f9e97f478b9b7ef7329bab7b69eebba1e60f6bc59

Verificações adicionais do modelo selecionado

Avaliação	Transações	Positivas	Precisão	Recall	AP
Teste principal	123.255	168	21,66%	99,40%	0,2597
Sem origens compartilhadas	28.121	168	25,38%	99,40%	0,2672
Temporal exploratória	121.496	1	0,1866%	100,00%	0,0141

Origens: mantém apenas transações sem endereço de entrada visto no desenvolvimento, sem reajustar o modelo. Não identifica pessoas ou carteiras. **Temporal:** reajusta nos blocos anteriores à altura 960766 e avalia os últimos 25% dos blocos; usa configuração já escolhida. Tem apenas 1 positivo, portanto é exploratória, não um novo teste intocado.

Conclusão

Há padrões úteis neste recorte, mas **alta recuperação não garante alertas confiáveis**. As 168 positivas do teste vêm de um único bloco; 500 das 504 positivas estão em quatro blocos próximos. A validação é instável e os dados dependem de um coletor conhecido. Não há evidência de generalização para novos ataques ou para toda a blockchain.